HƯỚNG DẪN CHIA DATASET

Dự Án Chatbox 2.0

Local English Vocabulary Chatbot — RAG Architecture

PhoBERT-base-v2 • BGE-M3 • BM25Okapi • Qwen2.5:7B • ChromaDB • LangChain

Kiến trúc:	Controlled Hybrid RAG Pipeline (100% Offline)
Knowledge Base:	3,725 cặp Q&A từ vựng tiếng Anh (CEFR A1-B2)
Intent Model:	PhoBERT Prototype-based Classification (Zero-shot)
Retrieval:	BM25Okapi + BGE-M3 Dense + RRF (k=60)
LLM:	Qwen2.5:7B via Ollama (Strict Grounding, T=0.0)

MỤC LỤC

1. Đặc Điểm Dự Án — Tại Sao Chia Dataset Khác ML Truyền Thống
2. Chiến Lược Chia Dataset Khuyến Nghị
3. Sơ Đồ Tổng Quan Chiến Lược
4. So Sánh RAG vs ML Truyền Thống
5. Hướng Dẫn Thực Hiện Từng Bước
6. Metrics Đánh Giá
7. Kết Luận & Tóm Tắt

Ngày tạo: 22/10/2026

1. ĐẶC ĐIỂM DỰ ÁN — TẠI SAO CHIA DATASET KHÁC ML TRUYỀN THỐNG

[!] QUAN TRỌNG

Dự án Chatbox 2.0 KHÔNG train/fine-tune model mà sử dụng kiến trúc RAG (Retrieval-Augmented Generation) kết hợp Prototype-based Intent Classification (zero-shot). Do đó, cách chia dataset sẽ KHÁC HOÀN TOÀN so với bài toán Machine Learning truyền thống (80/10/10).

Dự án có 2 loại "dataset" cần được phân biệt rõ ràng:

Loại dữ liệu	Mô tả	File liên quan
Knowledge Base (KB)	3,725 cặp Q&A về từ vựng tiếng Anh Đây là "bộ nhớ" để chatbot tra cứu	data/processed/qa_records.jsonl
Intent Prototypes	~25 câu mẫu tiếng Việt hardcode trong code để phân loại ý định	src/nlp/phobert_intent.py (dòng 28-71)

Knowledge Base chứa toàn bộ tri thức từ vựng mà chatbot sử dụng để trả lời. Nó được nạp vào ChromaDB (dense vector 1024 chiều) và BM25 Index (sparse keyword matching) để phục vụ truy xuất hybrid. Đây KHÔNG phải training data — đây là nguồn tra cứu.

Intent Prototypes là tập nhỏ ~25 câu mẫu tiếng Việt, mỗi intent có 4-6 câu. PhoBERT encode các câu mẫu thành vector 768 chiều, tính trung bình (centroid) cho mỗi intent, rồi so khớp cosine similarity với câu hỏi người dùng. Không có quá trình training/fine-tuning nào.

2. CHIẾN LƯỢC CHIA DATASET KHUYẾN NGHỊ

2.1 Chia Knowledge Base (3,725 cặp Q&A)

Vì đây là hệ thống RAG, toàn bộ Knowledge Base được nạp vào ChromaDB + BM25 Index để tra cứu. KHÔNG NÊN chia nhỏ KB thành train/test theo kiểu ML truyền thống — vì bạn cần chatbot trả lời được TẤT CẢ từ vựng.

KNOWLEDGE BASE (3,725 Q&A)

→ 100% nạp vào ChromaDB + BM25 (Production Index)

→ Giữ nguyên toàn bộ, KHÔNG chia nhỏ



EVALUATION SET (Tách riêng, KHÔNG lấy từ KB)

→ Tự soạn 50-100 câu hỏi kiểm thử chất lượng RAG

→ Dùng câu hỏi tự nhiên khác hoàn toàn so với KB

[TIP] MẸO QUAN TRỌNG

Không chia 80/20 từ KB! Nếu bỏ 20% từ vựng ra khỏi index, chatbot sẽ không trả lời được 20% câu hỏi → kết quả test không phản ánh đúng chất lượng hệ thống. Đây là lỗi phổ biến nhất khi áp dụng tư duy ML truyền thống vào hệ thống RAG.

2.2 Chia Evaluation Set Cho Retrieval Quality

Tạo một tập đánh giá RIÊNG BIỆT để đo chất lượng truy xuất (retrieval quality). Tập này phải gồm các câu hỏi tự nhiên mà người dùng thực sự sẽ hỏi, KHÔNG copy từ trường 'question' trong KB.

Tập	Số lượng	Mục đích	Cách tạo
Retrieval Test Set	50-100 câu	Đo Recall@3, MRR, Hit Rate của Hybrid Retriever	Tự viết câu hỏi tự nhiên + gán expected_record_id
LLM Response Quality Set	20-30 câu	Đo chất lượng câu trả lời sinh ra từ Qwen2.5	Viết câu hỏi + kiểm tra expected_answer_keywords
Rubric Test Set	15 câu	Đánh giá theo rubric đồ án (đã có sẵn)	tests/fixtures/ rubric_test_cases.json

2.3 Cấu Trúc File Retrieval Test Set

Đề xuất cấu trúc file tests/fixtures/retrieval_eval_set.json:

JSON

```
[
  {
    "test_id": "RET-001",
    "query": "từ abandon nghĩa là gì?",
    "expected_word": "abandon",
    "expected_record_ids": ["abandon_define_001"],
    "category": "exact_match"
  },
  {
    "test_id": "RET-002",
    "query": "từ nào có nghĩa là từ bỏ?",
    "expected_word": "abandon",
    "category": "vietnamese_to_english"
  },
  {
    "test_id": "RET-003",
    "query": "cho tôi các từ tiếng Anh trình độ B1",
    "expected_level": "B1",
    "category": "level_list"
  }
]
```

2.4 Chia Intent Prototypes (PhoBERT NLU)

Hiện tại, PhoBERT sử dụng Prototype-based Classification (zero-shot, không train). Tốt nhất là tạo Intent Test Set RIÊNG — dùng câu hỏi khác hoàn toàn so với các prototype đã dùng để tính centroid, tránh data leakage.

Đề xuất cấu trúc file tests/fixtures/intent_eval_set.json:

```JSON
[
  {"query": "nghĩa của từ ability là gì vậy?",
   "expected_intent": "DEFINE_VOCAB"},
  {"query": "dùng từ ability trong câu đi",
   "expected_intent": "GET_EXAMPLE"},
  {"query": "liệt kê từ vựng A2 cho tôi",
   "expected_intent": "GET_LEVEL_LIST"},
  {"query": "tiếng Anh của khả năng là gì?",
   "expected_intent": "TRANSLATE_VIE_TO_ENG"},
  {"query": "thế còn ví dụ?",
   "expected_intent": "FOLLOW_UP"},
  {"query": "ai là tổng thống Mỹ?",
   "expected_intent": "OUT_OF_SCOPE"},
  {"query": "từ đó nghĩa là gì?",
   "expected_intent": "AMBIGUOUS"}
]
```

[!] LƯU Ý

Intent Test Set phải dùng câu hỏi KHÁC HOÀN TOÀN so với các prototype đã dùng để tính centroid (dòng 28-71 trong phobert_intent.py), để tránh "data leakage" — tình trạng mô hình được test trên chính dữ liệu đã dùng để xây dựng centroids.

3. SƠ ĐỒ TỔNG QUAN CHIẾN LƯỢC CHIA DATASET

DATASET TỔNG THỂ CỦA DỰ ÁN

Bao gồm tất cả nguồn dữ liệu phục vụ chatbot



Knowledge Base

3,725 Q&A

→ 100% vào Production

→ ChromaDB + BM25

→ KHÔNG CHIA

Intent Prototypes

~25 câu mẫu

→ Giữ nguyên trong code

→ Làm Prototype Centroids

→ KHÔNG CHIA

Evaluation Sets (TẠO MỚI)

Soạn riêng biệt

→ Retrieval Test: 50-100 câu

→ Intent Test: 30-50 câu

→ Rubric Test: 15 câu (có sẵn)

4. SO SÁNH: RAG SYSTEM vs ML TRUYỀN THỐNG

Tiêu chí	ML Truyền thống (80/10/10)	RAG System (Chatbox 2.0)
Mục đích train set	Train model weights	KHÔNG train — KB là nguồn tra cứu
Mục đích val set	Tune hyperparameters	Tune RRF k, ngưỡng threshold
Mục đích test set	Đánh giá model cuối cùng	Đánh giá retrieval + generation quality
Rủi ro khi chia KB	Mất data training (chấp nhận được)	Mất từ vựng → chatbot trả lời sai (NGHIÊM TRỌNG)
Cách đúng	Chia từ training data 80% train / 10% val / 10% test	Giữ nguyên KB 100% Tạo eval set RIÊNG

[!] CẢNH BÁO

Nếu chia 80/20 từ Knowledge Base: 20% từ vựng (~745 từ) sẽ bị loại khỏi index → chatbot sẽ trả lời "Xin lỗi, dữ liệu hiện tại chưa có thông tin..." cho 745 từ đó → kết quả test cho thấy chatbot kém, nhưng thực tế là do THIẾU DATA chứ không phải do hệ thống hoạt động sai!

5. HƯỚNG DẪN THỰC HIỆN CỤ THỂ

Bước 1 Giữ nguyên Knowledge Base — Nạp 100%

Nạp toàn bộ 3,725 cặp Q&A vào index (đã làm trong dự án):

```
BASH
python ingest_data.py --file "data/processed/qa_records.jsonl" --mode replace
```

Bước 2 Tạo Retrieval Evaluation Set

Tạo file tests/fixtures/retrieval_eval_set.json với 50-100 câu hỏi tự nhiên. Phân bổ đều theo các nhóm sau:

Nhóm câu hỏi	Số câu	Ví dụ minh họa
Exact match (hỏi nghĩa trực tiếp)	15-20	"abandon nghĩa là gì?"
Paraphrase (diễn đạt lại)	10-15	"bạn có thể giải thích từ abandon không?"
Cross-lingual (hỏi bằng tiếng Anh)	5-10	"What does abandon mean in Vietnamese?"
Vietnamese → English (dịch Việt-Anh)	10	"từ nào có nghĩa là từ bỏ?"
Level list query (danh sách theo cấp độ)	5	"danh sách từ trình độ A1"
Multi-turn follow-up (câu hỏi nối tiếp)	5-10	"còn ví dụ?" (sau khi hỏi nghĩa từ)

Bước 3 Tạo Intent Evaluation Set

Tạo file tests/fixtures/intent_eval_set.json với 30-50 câu, mỗi intent ít nhất 5 câu. Đảm bảo câu hỏi KHÁC với prototype centroids.

Intent	Số câu tối thiểu	Nguyên tắc viết câu test
DEFINE_VOCAB	5-7	Hỏi nghĩa từ, dùng cách diễn đạt khác prototype
GET_EXAMPLE	5-7	Xin ví dụ, đặt câu, ngữ cảnh sử dụng
GET_LEVEL_LIST	4-5	Hỏi danh sách theo trình độ A1/A2/B1/B2
TRANSLATE_VIE_TO_ENG	5-7	Dịch từ tiếng Việt sang tiếng Anh

Intent	Số câu tối thiểu	Nguyên tắc viết câu test
FOLLOW_UP	5-7	Câu nối tiếp: "còn...", "thế còn..."
OUT_OF_SCOPE	5-7	Thời tiết, địa lý, toán, lịch sử...
AMBIGUOUS	4-5	Câu thiếu từ mục tiêu: "từ này", "từ đó"

6. METRICS ĐÁNH GIÁ CHẤT LƯỢNG

Sau khi tạo xong các evaluation set, sử dụng các metric sau để đo lường và báo cáo chất lượng hệ thống:

Metric	Áp dụng cho	Công thức / Mô tả	Ngưỡng tốt
Hit Rate @3	Retrieval	% câu hỏi mà đáp án đúng nằm trong top-3 kết quả	≥ 90%
MRR (Mean Reciprocal Rank)	Retrieval	Trung bình 1/rank của đáp án đúng đầu tiên	≥ 0.80
Recall @K	Retrieval	% đáp án đúng được truy xuất trong top-K kết quả	≥ 85%
Intent Accuracy	PhoBERT NLU	% câu hỏi được phân loại đúng intent	≥ 85%
Answer Relevance	LLM Response	Đánh giá thủ công câu trả lời có đúng & đầy đủ không	≥ 90%
Latency P95	End-to-end	95th percentile thời gian phản hồi	< 5 giây
Faithfulness	LLM Response	Câu trả lời có bám sát context hay hallucination	100%

6.1 Công Thức Hit Rate @K

Hit Rate @K = (Số câu hỏi có expected_record_id nằm trong top-K kết quả) / (Tổng số câu hỏi test)

Ví dụ: Nếu có 100 câu test, 92 câu có đáp án đúng trong top-3 → Hit Rate @3 = 92%.

6.2 Công Thức MRR

MRR = (1/N) × Σ(1/rank_i) — với rank_i là vị trí của đáp án đúng đầu tiên trong kết quả truy xuất.

Ví dụ: Câu 1 đáp án ở vị trí 1 (1/1=1.0), câu 2 ở vị trí 3 (1/3=0.33) → MRR = (1.0+0.33)/2 = 0.67.

7. KẾT LUẬN & TÓM TẮT

[i] TÓM TẮT CHIẾN LƯỢC CHIA DATASET

1) Knowledge Base (3,725 Q&A) → KHÔNG CHIA — giữ 100% trong production index.
2) Evaluation → TẠO RIÊNG bộ test 50-100 câu hỏi tự nhiên (không trùng KB).
3) Intent Prototypes → Giữ nguyên trong code, tạo riêng 30-50 câu test intent.
4) Rubric Test → Đã có sẵn 15 ca trong tests/fixtures/rubric_test_cases.json.

Cách chia này đảm bảo:

- [V] Chatbot trả lời được TẤT CẢ từ vựng (không mất data)
- [V] Đánh giá khách quan bằng câu hỏi mới (không data leakage)
- [V] Phù hợp rubric đồ án (15 ca test + bộ test mở rộng)
- [V] Có thể tune hyperparameters (RRF k, threshold) dựa trên eval set
- [V] Đo lường được chất lượng retrieval bằng metric chuẩn (Hit Rate, MRR)

Những điều KHÔNG NÊN làm:

- [X] Chia 80/10/10 từ Knowledge Base — chatbot sẽ mất từ vựng
- [X] Dùng câu hỏi trong KB làm test — data leakage
- [X] Copy prototype câu mẫu từ code ra làm intent test — data leakage
- [X] Chỉ test 15 ca rubric mà không có retrieval quality eval — thiếu depth

GHI NHỚ CUỐI CÙNG

Dự án RAG ≠ Dự án ML truyền thống.

Knowledge Base = Nguồn tra cứu, KHÔNG PHẢI training data.

Evaluation Set = Tự soạn riêng, KHÔNG trùng với KB.

Mục tiêu: Đo Retrieval Quality + Intent Accuracy + Response Faithfulness.